

“Predicción Automatizada de Neumonía a Partir de Imágenes de Rayos X Utilizando Redes Neuronales Convolucionales (CNN)”

1. CONTEXTO DE APLICACIÓN

La neumonía es una infección pulmonar que afecta a millones de personas en el mundo cada año y representa una de las principales causas de hospitalización y mortalidad, especialmente en niños y adultos mayores. En regiones con recursos limitados, el diagnóstico temprano es un desafío debido a la falta de radiólogos y equipos de diagnóstico avanzados.

En este contexto, el uso de técnicas de **aprendizaje profundo (Deep Learning)** aplicadas a imágenes médicas se ha convertido en una herramienta prometedora para apoyar el diagnóstico clínico. En particular, las **redes neuronales convolucionales (CNN)** han mostrado resultados sobresalientes en tareas de clasificación de imágenes radiológicas.

Este proyecto se desarrolla con el propósito de construir un modelo de Deep Learning capaz de **detectar automáticamente casos de neumonía a partir de radiografías de tórax**, utilizando imágenes disponibles en repositorios públicos.

2. OBJETIVO DEL PROYECTO

El objetivo de este proyecto es desarrollar un modelo de aprendizaje profundo capaz de detectar neumonía en imágenes de rayos X de tórax, utilizando técnicas de redes neuronales convolucionales (CNN).

En concreto, se busca predecir si una imagen radiográfica corresponde a un paciente con neumonía o a un individuo sano, a partir de las características visuales presentes en las imágenes (como opacidades pulmonares, infiltrados o alteraciones estructurales).

3. DESCRIPCIÓN DEL DATASET

Para el desarrollo del proyecto se utilizará el conjunto de datos Chest X-Ray Images (Pneumonia), publicado en el repositorio Kaggle (fuente:

<https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>).

Este dataset contiene imágenes de rayos X de tórax (en formato JPEG) recopiladas de pacientes pediátricos del Guangzhou Women and Children's Medical Center (China). Las imágenes fueron clasificadas por radiólogos certificados en dos categorías principales:

- **NORMAL:** pacientes sin evidencia radiológica de neumonía.
- **PNEUMONIA:** pacientes diagnosticados con neumonía, incluyendo casos bacterianos y virales.

El dataset ya se encuentra dividido en los tres subconjuntos:

Subconjunto	Nº de imágenes	Tamaño aproximado	Propósito
Entrenamiento	5216	1.2 GB	Ajuste de pesos del modelo

Validación	16	10 MB	Evaluación durante el entrenamiento
Prueba	624	150 MB	Evaluación final del modelo

En total, el dataset cuenta con aproximadamente 5,856 imágenes, con resoluciones que varían entre $1,024 \times 1,024$ y $2,048 \times 2,048$ píxeles.

Además, la distribución de clases no es completamente balanceada, ya que para la neumonía se tienen 4273 imágenes que representan el 73% de la data, mientras que para los pacientes normales se tienen 1583 imágenes, las cuales representan el 27%.

4. MÉTRICAS DE DESEMPEÑO

4.1. Métricas de Machine Learning

Dado que se trata de una **clasificación binaria (neumonía / normal)**, se utilizarán las siguientes métricas:

- **Accuracy:** proporción total de predicciones correctas.
- **Precision:** mide cuántas predicciones de neumonía fueron realmente correctas.
- **Recall (sensibilidad):** mide la capacidad del modelo para detectar todos los casos de neumonía.
- **F1-Score:** balance entre precisión y sensibilidad, útil ante clases desbalanceadas.
- **AUC-ROC:** mide la capacidad global del modelo para distinguir entre ambas clases.

Métricas de impacto clínico

Dado que se trata de una **clasificación binaria (neumonía / normal)**, se utilizarán las siguientes métricas:

- **Accuracy:** proporción total de predicciones correctas.
- **Precision:** mide cuántas predicciones de neumonía fueron realmente correctas.
- **Recall (sensibilidad):** mide la capacidad del modelo para detectar todos los casos de neumonía.
- **F1-Score:** balance entre precisión y sensibilidad, útil ante clases desbalanceadas.
- **AUC-ROC:** mide la capacidad global del modelo para distinguir entre ambas clases.

4.2. Métricas de impacto clínico

- Tasa de detección temprana de neumonía.
- Reducción del tiempo diagnóstico del personal médico.
- Minimización de falsos negativos (FN), críticos en salud.
- Tiempo de inferencia para evaluar la aplicabilidad en entornos clínicos.

5. REFERENCIAS Y RESULTADOS PREVIOS

Un estudio de **Kermany et al. (2018)**, utilizando el mismo dataset de **Chest X-Ray Pneumonia (Kaggle)**, logró una **precisión del 92.8%** y **una sensibilidad del 93.2%** mediante un modelo basado

en **transfer learning con InceptionV3**. Otros trabajos recientes han empleado arquitecturas como **ResNet50, DenseNet121 y VGG16**, alcanzando valores de **AUC superiores a 0.95**.

Estos resultados sugieren que los modelos de deep learning pueden convertirse en herramientas de apoyo clínico para **priorizar estudios sospechosos y reducir la carga de trabajo en radiología**, siempre y cuando se mantenga una validación rigurosa y se controlen los posibles sesgos en los datos.

REFERENCIAS BIBLIOGRÁFICAS:

Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C. S., Liang, H., Baxter, S. L., ... & Zhang, K. (2018). *Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning*. *Cell*, 172(5), 1122–1131.e9. <https://doi.org/10.1016/j.cell.2018.02.010>